

Konzept für Sensor Based Activity Recognition Challenge

Student:innen: Jessica Schmid, Silas Tschopp, Raphael Schüpbach

Fachexperte: Marcel Messerli

Projektbeschreibung

Ziel der Challenge ist es, ein Modell zu trainieren, das folgende sieben Bewegungstypen klassifizieren kann:

- Zug
- Auto
- Fahrrad
- Treppen steigen
- Gehen
- Lift
- Round-Kick

Schlussendlich wird ein Dashboard bereitgestellt, auf dem man seine Bewegungsdaten hochladen kann, und das Modell versucht zu erkennen, um welchen Bewegungstyp es sich handelt.

Genauigkeit:

Unser Ziel ist eine Genauigkeit von etwa 85 %. Zur Bewertung der Modelleistung verwenden wir den Macro-F1-Score, da dieser alle Klassen gleich gewichtet. Da wir davon ausgehen, dass nicht für alle Klassen gleich viele Trainingsdaten verfügbar sind, eignet sich diese Metrik besser als die reine Accuracy oder der normale F1-Score.

Eine Genauigkeit von rund 85 % erscheint realistisch, da andere Human-Activity-Recognition-Projekte mit Sensordaten von Smartphones häufig Genauigkeiten zwischen etwa 80 % und 95 % erreichen. Gleichzeitig erwarten wir gewisse Schwierigkeiten bei Bewegungen, die sich in ihren Sensormustern ähneln (z. B. verschiedene Transportarten wie Zug oder Auto), weshalb wir ein etwas niedrigeres Ziel ansetzen.

Scope des Projektes

Was wir erreichen wollen:

- Wir wollen mindestens ein ML-Modell und ein DL-Modell trainieren und miteinander vergleichen.
- **Weights & Biases (wandb.ai)** wird verwendet, um Trainingsläufe, Hyperparameter und Evaluationsmetriken zu protokollieren und verschiedene Modelle systematisch zu vergleichen.
- Ein anschauliches Dashboard erstellen, auf dem Nutzende sehr einfach Daten hochladen können und erfahren, welchen Bewegungstyp das Modell erkennt.

- Die Daten manuell zuschneiden, damit nur die Sensordaten des jeweiligen Bewegungstyps enthalten sind.
- Die Aufzeichnungen enthalten folgende Sensoren: Accelerometer, Gyroscope und Orientation.

Was wir nicht erreichen wollen:

- Wir behandeln ausschliesslich Daten, die mit Smartphones aufgenommen wurden.
- Der Fokus liegt auf einem funktionalen Dashboard. Die Modelle werden verglichen, analysiert und verbessert, jedoch nicht bis ins kleinste Detail optimiert.
- Das Dashboard dient ausschliesslich der Klassifikation des Bewegungstyps und nicht zur Vorhersage zukünftiger Bewegungen.

Optionale Ziele

- Wenn wir am Schluss genügend Zeit haben, möchten wir das Modell weiter optimieren, damit es auch mehr Bewegungstypen in einer Aufnahme erkennen kann.

Milestones

Was	Wann
Konzept/Planung	20.3.2026
Daten Sammlung abgeschlossen	5.4.2026
Daten einlesen und zuschneiden	5.4.2026
Feature Engineering und erstes ML-Modell	15.4.2026
Machine Learning Modelle trainieren und optimieren	25.4.2026
Deep Learning Modell entwickeln	15.5.2026
Modelle verglichen und bestes ausgewählt	20.5.2026
Dashboard erstellt und getestet	31.5.2026
Abgabe Challenge	7.6.2026
Präsentation	18.6.2026

Wir werden einen detaillierteren Plan im Excel erstellen und benutzen.

Umgang mit den Daten

Datensicherung / Datenbeschriftung:

Die Bewegungsdaten werden alle mit der App Sensor Logger erfasst. Anschliessend werden die Daten als gezipptes CSV in einen gemeinsamen OneDrive-Ordner exportiert. Wir arbeiten mit sogenannten *Tags*: Jede Aufnahme erhält einen Tag, der die Aufnahme kennzeichnet. Dieser Tag wird in einem separaten Ordner innerhalb des ZIP-Ordners gespeichert, wodurch die Daten anschliessend eindeutig gelabelt werden können.

Die Daten unseres Projekts werden mit **DVC (Data Version Control)** in einem externen DVC-Storage gespeichert. So können grosse Datensätze versioniert, reproduzierbar verwaltet und effizient gespeichert werden, ohne dass das Git-Repository unnötig vergrössert wird.

Datenverarbeitung:

- Die Aufzeichnungen werden manuell zugeschnitten, da zu Beginn und am Ende der Aufnahme noch keine relevante Bewegung stattfindet.
- Die Sensoraufnahmen werden mit einer Samplingfrequenz von 120 Hz durchgeführt. Um die Konsistenz der Daten sicherzustellen, werden die Aufzeichnungen dennoch überprüft und gegebenenfalls auf 120 Hz resampled, falls eine Aufnahme mit einer anderen Frequenz erstellt wurde, beispielsweise wenn Nutzende eigene Daten in das Dashboard hochladen.
- Anschliessend werden die Daten in **gleich lange Sequenzen (Sliding Windows)** unterteilt, sodass die Modelle Eingaben mit identischer Länge erhalten.
- Fehlende Sensordaten werden erkannt und durch Interpolation geschätzt, sodass eine möglichst vollständige und gleichmässige Zeitreihe für die Modellierung entsteht.

Modellierung:

- Der Datensatz wird mit einem **80/20 Train-Test-Split** aufgeteilt, um die Klassenverteilung in beiden Sets zu erhalten. (Split nach Aufnahme)
- Verschiedene **Machine-Learning-Modelle** werden trainiert, um erste Modelle für die Klassifikation zu erstellen.
- Mehrere **Deep-Learning-Modelle** werden entwickelt, um komplexe Muster in den Sensordaten zu erkennen.
- **Hyperparameter-Tuning mit Cross-Validation** optimiert die Modellleistung und verhindert Overfitting.
- Alle Experimente, Trainingsverläufe und Metriken werden mit Weights & Biases protokolliert.
- Die Modelle werden anhand von **Makro F1-Score** evaluiert, um die Leistung umfassend zu beurteilen.
- Abschliessend werden ML- und DL-Modelle miteinander verglichen, um das leistungstärkste Modell auszuwählen.

Output

Am Schluss unserer Challenge möchten wir ein funktionales Dashboard haben, welches in der Lage ist, Bewegungsmuster zu klassifizieren. Es soll dabei möglich sein eine Zip-Datei des App Sensor-Logger raufzuladen. Nach dem Hochladen sieht man einige Grafiken zu der eigenen Aufnahme wie auch die Vorhersage des Modells.

Ausserdem liefern wir ein gut strukturiertes und dokumentiertes Git-Repository sowie eine abschliessende Präsentation, welche unsere Ergebnisse präsentiert.